机器学习课程算法仿真与对比分析报告
基于 K-means、SVM、BP 网络与 RBF 网络

李承锦（学号：202521011635）
https://github.com/ChengjinLii/machine_learning_project

2026 年 4 月 20 日

Abstract

本文围绕机器学习课程中的典型算法，选取 K-means、支持向量机（SVM）、BP 神经网络和径向基函数（RBF）网络四类方法进行仿真，并补充参数敏感性与结构对比实验。实验数据来自 Iris、Wine 和 Fashion-MNIST 三个开源数据集，数据获取、预处理、训练、评估与可视化均在同一仓库中完成，代码开源地址为 https://github.com/ChengjinLii/machine_learning_project。

实验结果表明：在 Iris 数据集上，采用 $K = 3$ 的 K-means 聚类可得到 0.6201 的调整兰德指数和 0.6595 的归一化互信息；在 Wine 数据集上，RBF 核 SVM 的测试准确率为 97.78%，基于 K-means 选中心的 RBF 网络在 9 个隐层中心时测试准确率为 100%；在 Fashion-MNIST 子集上，三层隐藏结构的 BP/MLP 网络测试准确率为 86.275%。附加实验表明，聚类内部指标与外部一致性指标之间存在差异，RBF 网络对隐层中心数敏感，BP 网络则呈现出精度与计算代价之间的折中关系。

关键词 机器学习, K-means, 支持向量机, BP 神经网络, RBF 网络

1 引言

机器学习课程通常围绕监督学习、无监督学习和神经网络三条主线展开。为将课件中的理论内容落实为可复现的实验结果，本文从课程资料中选取四类代表性算法完成仿真：无监督聚类中的 K-means，统计学习中的支持向量机，前馈神经网络中的 BP 网络，以及具备局部基函数建模能力的 RBF 网络。

除给出主实验结果外，本文还补充了多组对比实验，以分析模型在不同参数设置下的性能变化。具体而言，K-means 部分比较不同簇数 K 的聚类结果，SVM 部分比较不同核函数，RBF 网络部分比较不同隐层中心数，BP 网络部分比较不同多层感知机结构。通过这些实验，可进一步考察各类算法在不同数据集和参数条件下的表现。

2 算法原理与实验对象

2.1 K-means 聚类

K-means 是最经典的原型聚类算法之一，其核心思想是给定簇数 K 后，交替执行“样本分配”和“中心更新”两个步骤，以最小化簇内平方误差和 [1]：

$$\min_{\{\mathcal{C}_k\},\{\mu_k\}} \sum_{k=1}^{K} \sum_{x_i \in \mathcal{C}_k} \|x_i - \mu_k\|_2^2. \tag{1}$$

K-means 不依赖标签信息，适用于分析样本的自然分组结构。本文在 Iris 数据集上验证其聚类效果，并比较不同 K 值对应的性能变化。

2.2 支持向量机

支持向量机通过最大化分类间隔寻找最优分离超平面，是统计学习理论中极具代表性的二分类方法 [2]。对于线性可分情形，其基本优化问题为

$$\min_{w,b} \frac{1}{2}\|w\|_2^2, \qquad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1. \tag{2}$$

实际问题往往并非线性可分，因此可通过核技巧构造隐式高维映射。本文在 Wine 数据集上比较线性核、多项式核、Sigmoid 核和 RBF 核的表现。

2.3 BP 神经网络

BP 神经网络通过误差反向传播求解多层前馈网络参数 [3]。在输出层得到损失后，梯度逐层向前传播，并据此更新网络权值。本文采用多层感知机（MLP）作为 BP 网络的工程实现，该结构与课件中的“输入层-隐层-输出层”模型一致，便于在图像分类任务上进行对比实验。

2.4 RBF 网络

RBF 网络通常由输入层、RBF 隐层和线性输出层构成。若隐层采用高斯基函数，则第 j 个单元的响应可写为 [4]

$$\phi_j(x) = \exp\left(-\gamma \|x - c_j\|_2^2\right), \tag{3}$$

其中 c_j 为第 j 个中心。课程课件中明确介绍了“先以 K-means 确定中心，再通过最小二乘法确定输出层权值”的训练思路，本文严格按照这一思路实现多分类 RBF 网络，并比较不同隐层中心数下的表现。

2.5 数据集说明

本文使用 3 个公开数据集，覆盖传统表格数据与图像数据两类任务场景。

表 1: 本文使用的数据集概况

数据集	总样本数	特征维度	类别数	训练样本	测试样本	来源
Iris	150	4	3	–	–	UCI
Wine	178	13	3	133	45	UCI
Fashion-MNIST	70000	784	10	12000	4000	Zalando 发布数据

Iris 数据集最早由 Fisher 用于多变量分类研究 [5]，并可从 UCI 机器学习仓库获取 [6]。Wine 数据集同样来自 UCI 机器学习仓库 [7]，包含三类葡萄酒在 13 个理化属性上的测量结果。Fashion-MNIST 数据集由 Xiao 等提出 [8]，常用作入门级图像分类基准。

3 实验环境与评价指标

3.1 软件环境

实验在统一的 Python/conda 环境中完成。为支持数据读取、数值计算、模型训练与结果可视化，环境中需包含 `numpy`、`pandas`、`matplotlib`、`scikit-learn`、`scipy`、`seaborn` 和 `requests` 等依赖库。为保证各算法实验在同一配置下运行，本文采用统一环境安装和管理上述依赖，以减少库版本差异对实验结果的影响。

3.2 预处理与评价指标

不同实验采用统一的预处理方案。Iris 与 Wine 数据均进行标准化处理，以避免量纲差异影响距离或间隔计算；Fashion-MNIST 图像像素被线性归一化到 $[0,1]$ 区间。监督学习实验采用准确率（Accuracy）和宏平均 F_1 值（Macro-F1）评估：

$$\text{Accuracy} = \frac{1}{N}\sum_{i=1}^{N} 1(\hat{y}_i = y_i). \tag{4}$$

对于多分类任务，宏平均 F_1 先分别计算各类别的 F_1 值，再取算术平均。

聚类实验额外采用 3 个指标：

- 轮廓系数（Silhouette），反映簇内紧凑性与簇间分离性。
- 调整兰德指数（ARI），评估聚类结果与真实类别的一致性。
- 归一化互信息（NMI），评估聚类标签与真实标签的信息共享程度。

4 主实验结果

4.1 总体结果汇总

四类算法在各自任务上的核心结果如表 2 所示。表格数据上的监督分类性能整体较高，其中 RBF 网络在该训练/测试划分下取得了 100% 的测试准确率；对于类别更多、样本形态更复杂的 Fashion-MNIST，BP 网络的准确率低于 Wine 分类任务，但仍保持在较高水平。

表 2: 四类算法主实验结果汇总

算法	数据集	关键设置	Accuracy / ARI	Macro-F1 / NMI	备注
K-means	Iris	$K = 3$	ARI = 0.6201	NMI = 0.6595	Silhouette = 0.4590
SVM	Wine	RBF 核	0.9778	0.9765	最优核函数
RBF 网络	Wine	9 个中心	1.0000	1.0000	该划分下最高
BP 网络	Fashion-MNIST	MLP(256,128,64)	0.8628	0.8631	30 个 epoch

4.2 K-means 聚类结果

图 1 展示了 Iris 数据集在 PCA 二维投影下的真实标签与聚类结果。setosa 类基本单独成簇，而 versicolor 与 virginica 存在一定重叠，因此 K-means 难以完全恢复真实类别边界。该实验的 ARI 为 0.6201，说明聚类结果与真实类别之间具有较强一致性。

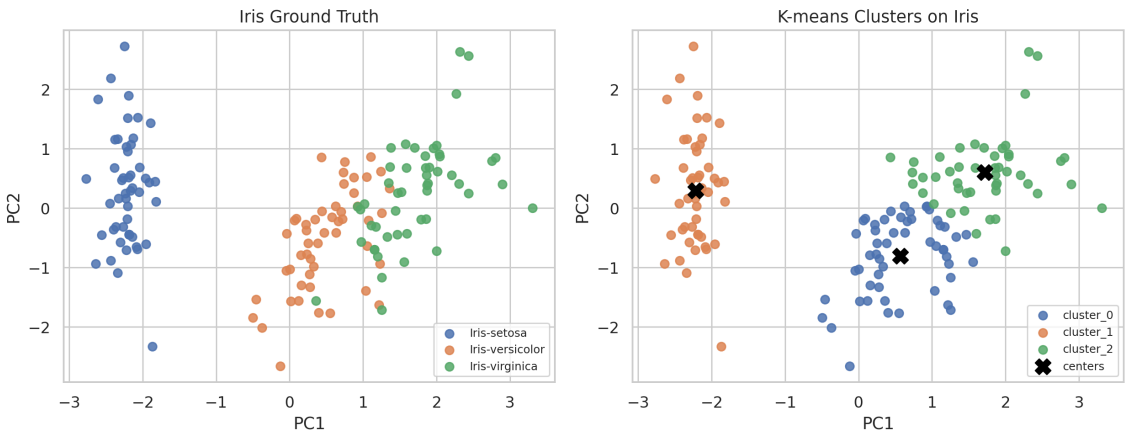


图 1: Iris 数据集上的 K-means 聚类结果

4.3 SVM 分类结果

SVM 主实验采用 RBF 核，其在 Wine 测试集上的准确率为 97.78%，宏平均 F_1 值为 0.9765。图 2 的混淆矩阵显示，大多数样本均被正确分类，仅存在少量跨类别误判。对于样本量较小且类别结构较清晰的表格数据，SVM 具有稳定的分类性能。

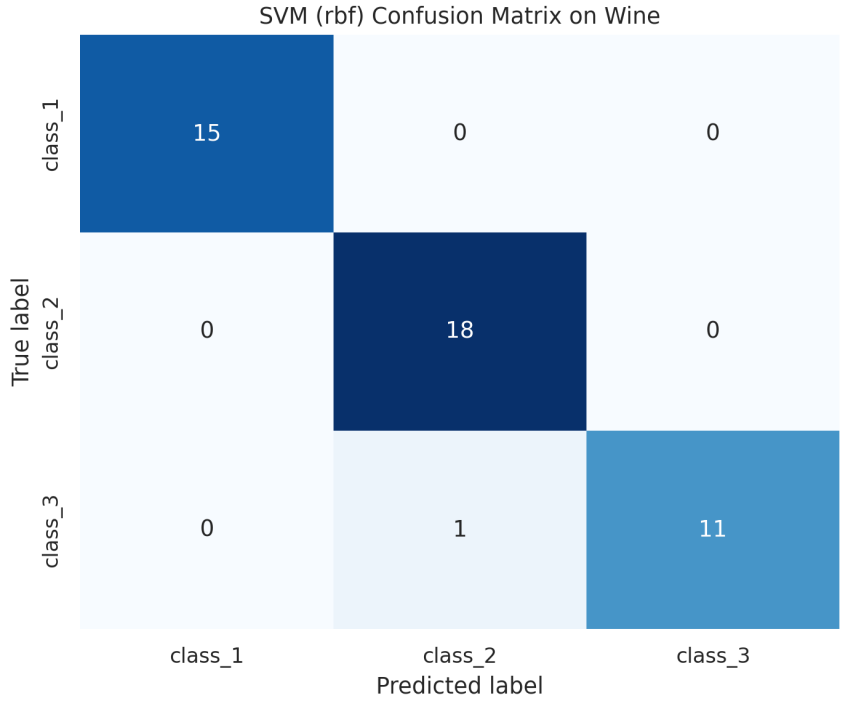


图 2: Wine 数据集上的 SVM 混淆矩阵

4.4 RBF 网络结果

图 3 给出了 RBF 网络在 Wine 数据集上的混淆矩阵。该实现与课件中“先聚类取中心，再线性输出”的结构一致。当隐层中心数取 9 时，测试集准确率和宏平均 F_1 值均达到 1.0000，表明局部基函数映射能够在该数据集上形成有效的判别边界。

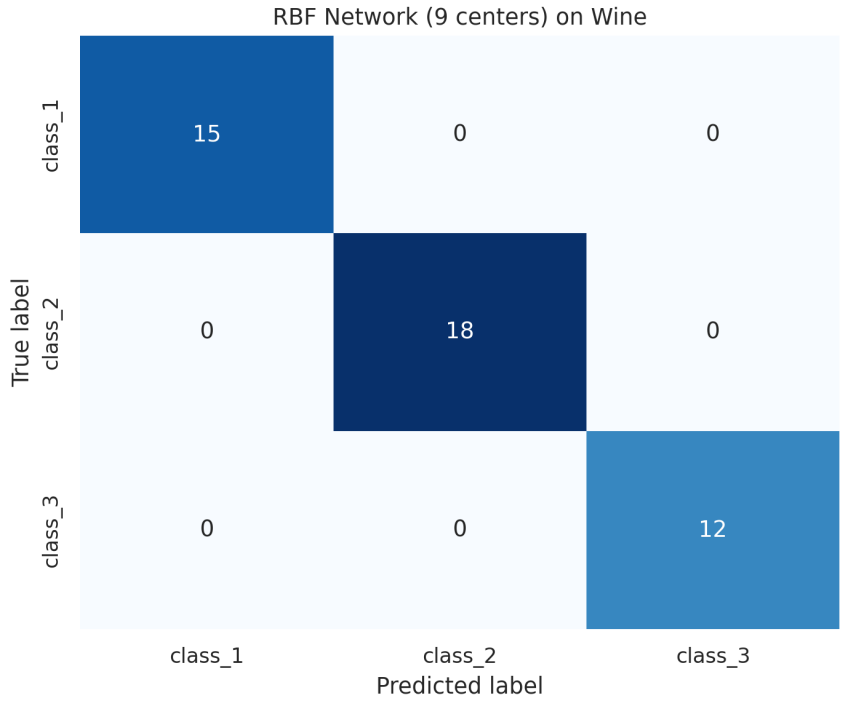


图 3: Wine 数据集上的 RBF 网络混淆矩阵

4.5 BP **网络结果**

BP 网络采用 Fashion-MNIST 子集进行训练与测试，测试性能最高的结构为 `MLP(256,128,64)`。如图 4 所示，训练损失随 epoch 增加而持续下降，表明网络在该样本规模上能够收敛。图 5 的混淆矩阵显示，服饰图像中的相近类别仍存在较多混淆，例如 T-shirt/top、Shirt 与 Pullover 之间的误分较为集中，这与图像本身的细粒度相似性一致。

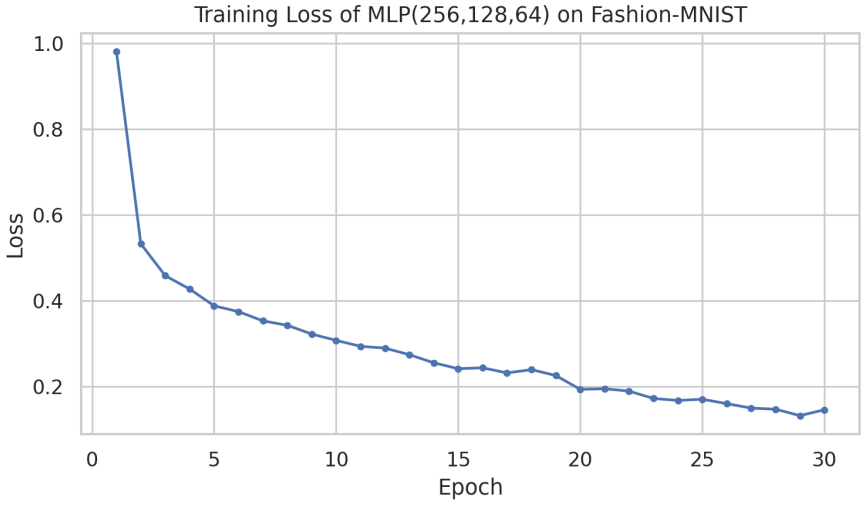


图 4: Fashion-MNIST 子集上的 BP/MLP 训练损失曲线

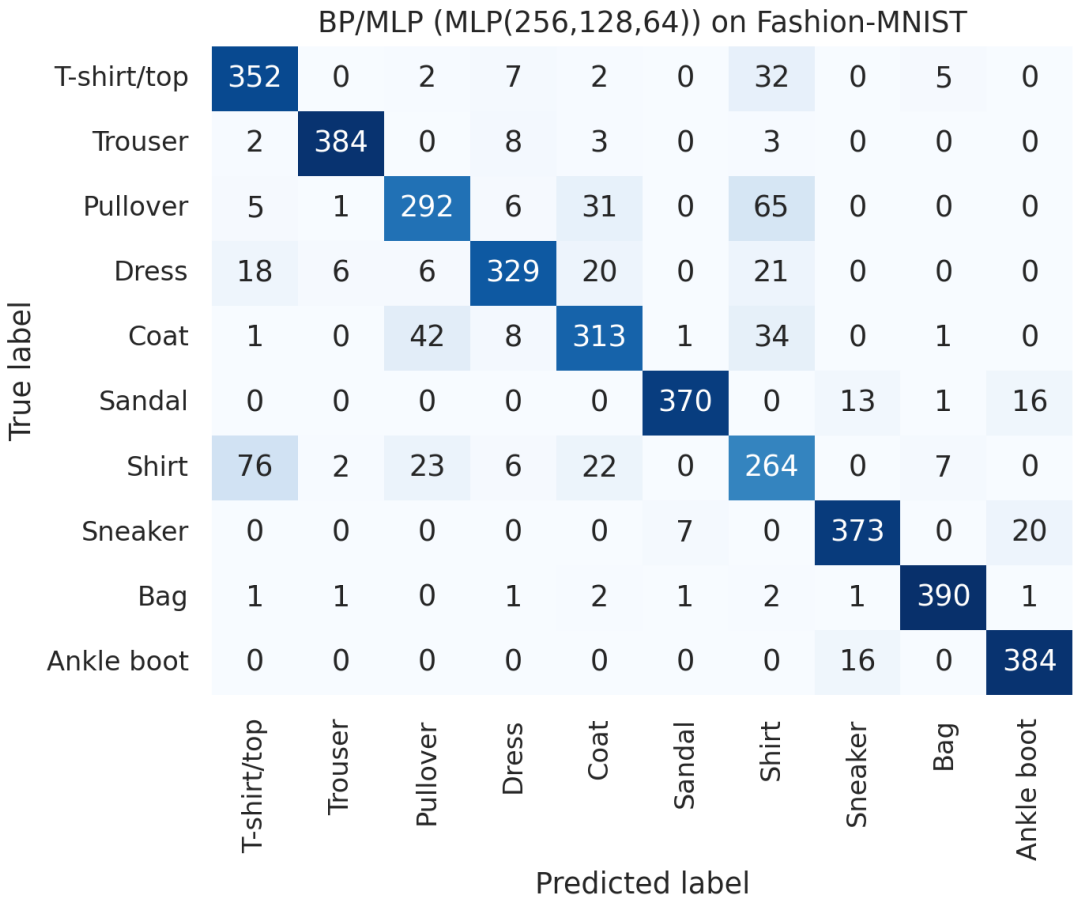


图 5: Fashion-MNIST 子集上的 BP/MLP 混淆矩阵

5 附加对比实验与分析

5.1 K-means 的簇数敏感性

为分析簇数选择对聚类结果的影响，本文进一步比较了 $K = 2, 3, 4, 5, 6$ 五种设置。对应结果见表 3 和图 6。

表 3: Iris 数据集上 K-means 的不同簇数比较

K	Inertia	Silhouette	ARI	NMI
2	223.7320	0.5802	0.5681	0.7337
3	140.9658	0.4590	0.6201	0.6595
4	114.3885	0.3874	0.4706	0.5967
5	91.0756	0.3516	0.4167	0.5873
6	80.1667	0.3259	0.3512	0.5374



图 6: Iris 数据集上 K-means 的簇数扫描结果

若仅考察轮廓系数，则 $K = 2$ 优于 $K = 3$；若引入真实标签进行外部评估，则 $K = 3$ 的 ARI 最高。该结果表明，内部聚类指标更偏向于刻画簇内紧凑性，而外部一致性指标更关注聚类结果与真实类别划分之间的对应关系。因此，聚类任务的评价不能依赖单一指标。

5.2 SVM 的核函数比较

表 4 和图 7 给出了不同核函数在 Wine 数据集上的表现。RBF 核取得最高准确率，线性核、多项式核和 Sigmoid 核的准确率均为 95.56%，而 RBF 核达到 97.78%。

表 4: Wine 数据集上不同 SVM 核函数比较

核函数	Accuracy	Macro-F1	运行时间/s
Linear	0.9556	0.9562	0.0020
RBF	0.9778	0.9765	0.0019
Polynomial	0.9556	0.9522	0.0017
Sigmoid	0.9556	0.9537	0.0017

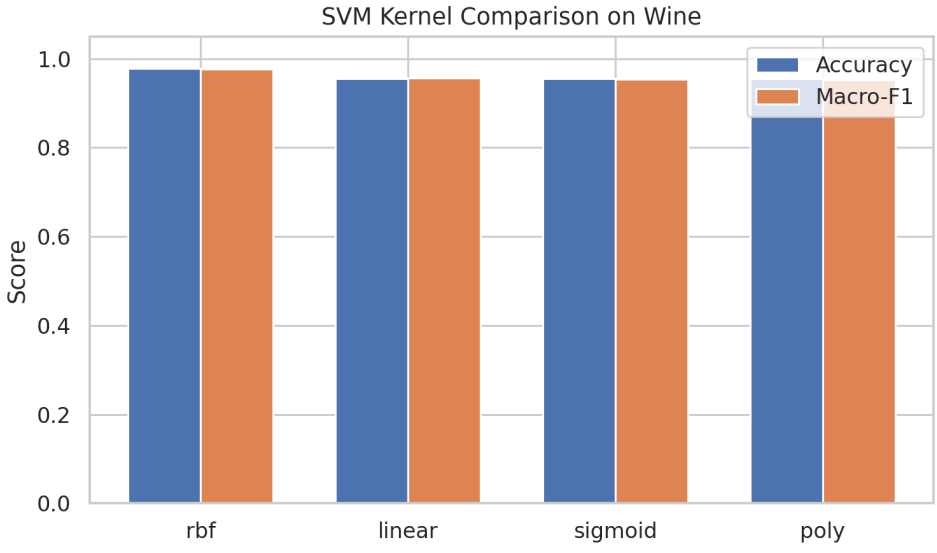


图 7: Wine 数据集上 SVM 核函数比较

该结果表明，Wine 数据集中的类别边界并非严格线性可分。RBF 核通过局部径向响应构造更灵活的决策边界，因此在较低运行开销下取得了最高的分类性能。

5.3 RBF 网络的中心数敏感性

RBF 网络的关键超参数是隐层中心数。若中心过少，模型表达能力不足；若中心过多，模型容易冗余甚至受到样本划分偶然性的影响。表 5 和图 8 展示了中心数扫描结果。

表 5: Wine 数据集上 RBF 网络的隐层中心数比较

中心数	Accuracy	Macro-F1	运行时间/s
6	0.9778	0.9765	0.0209
9	1.0000	1.0000	0.0281
12	0.9556	0.9522	0.0329
15	0.9556	0.9522	0.0382
18	0.9778	0.9765	0.0433
24	0.9556	0.9522	0.0553
30	0.9778	0.9765	0.0662

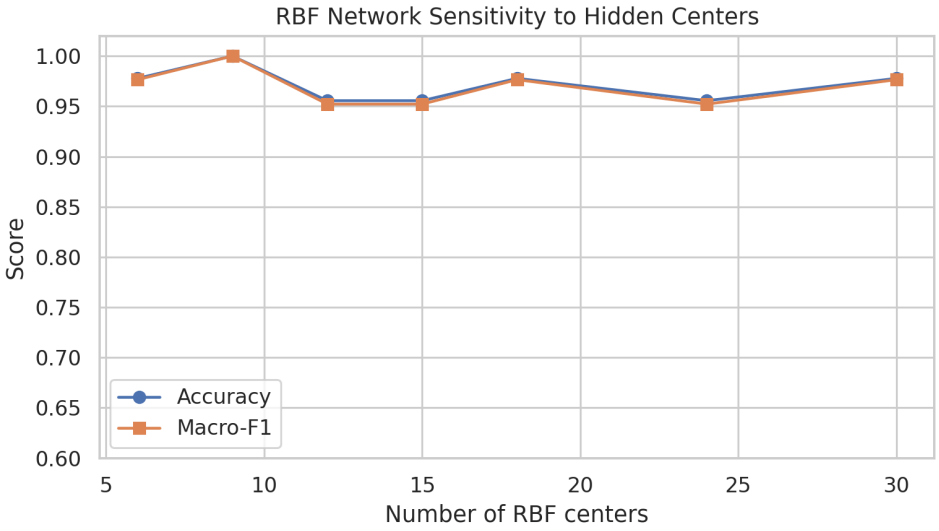


图 8: Wine 数据集上 RBF 网络对中心数的敏感性

结果表明，中心数并非单调增大越优。9 个中心对应最高测试性能，而 12、15 和 24 个中心对应的性能反而下降。对于小规模表格数据，RBF 网络的表达能力与泛化能力之间存在明显平衡点。课程课件中关于“中心选取对 RBF 性能具有重要影响”的结论在本实验中得到了验证。

5.4 BP 网络的结构比较

BP 网络部分额外比较了 3 种多层感知机结构，结果见表 6 和图 9。总体上，更深的网络带来更高的准确率，但也显著增加训练时间。

表 6: Fashion-MNIST 子集上不同 BP/MLP 结构比较

网络结构	Accuracy	Macro-F1	Epochs	运行时间/s
MLP(128)	0.8528	0.8521	22	1.6840
MLP(256,128)	0.8610	0.8606	18	2.7123
MLP(256,128,64)	0.8628	0.8631	30	4.9841

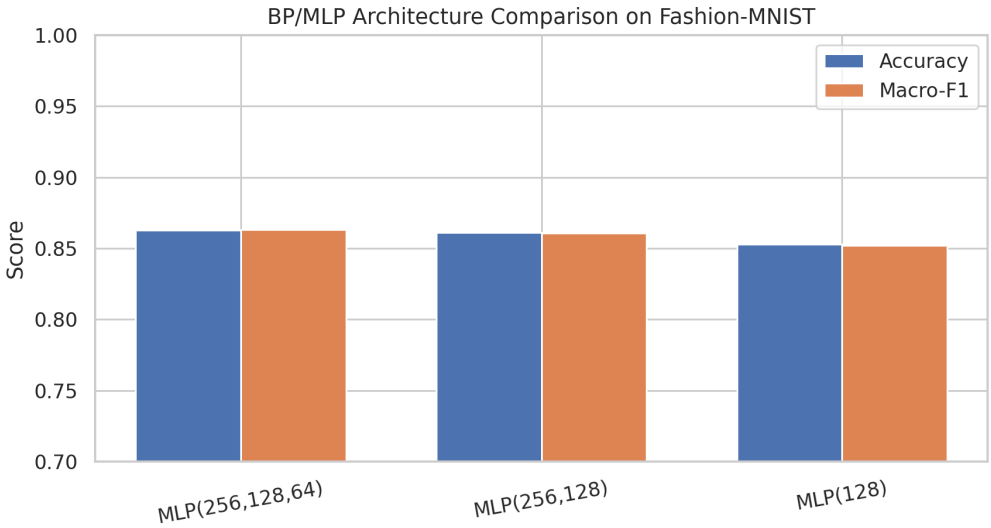


图 9: Fashion-MNIST 子集上的 BP/MLP 结构比较

与单层隐藏结构相比，增加网络深度后，模型对高维图像特征的表达能力增强，准确率有所提升。但从运行时间看，性能最高结构的训练时间约为最浅结构的 3 倍。若同时考虑精度与计算成本，`MLP(256,128)` 在两者之间表现出较平衡的结果；若优先考虑测试性能，则 `MLP(256,128,64)` 更合适。

6 综合讨论

6.1 不同算法的适用场景

综合全部实验，可以得到以下认识。

- K-means 可用于分析数据中的天然结构，但其优化目标并不直接对应真实标签，因此聚类质量不能简单等同于分类精度。
- SVM 适用于处理中小规模表格数据，在核函数选取得当时能够以较低时间开销获得较高性能。
- RBF 网络以“先局部表示、后线性判别”的方式完成分类，在该 Wine 数据划分下其测试性能高于 SVM。
- BP 网络具有较强的通用逼近能力，能够处理高维图像输入，但需要更多训练样本和更长训练时间。

6.2 实验结论的边界

尽管实验结果具有一定区分度，但仍需注意其适用边界。首先，Wine 数据集样本量较小，单次训练/测试划分下出现 100% 准确率并不意味着模型在更一般情形下一定优于其他方法，后续可通过增加交叉验证提高结论稳健性。其次，Fashion-MNIST 上使用的仍然是全连接 BP 网络，而非卷积网络，因此性能存在上限。再次，K-means 的结果受初始化、簇数和特征变换影响较大，若采用更多随机种子重复试验，结论将更加稳健。

6.3 与课程内容的对应关系

本报告的实验设计与课程内容具有明确对应关系。K-means 对应“非监督分类与聚类”课件，SVM 对应“线性分类与支持向量机”课件，BP 网络和 RBF 网络分别对应“常用人工神经网络”课件中的两类核心模型。同时，RBF 网络中用 K-means 选中心的实现方式，也体现了课程不同章节之间的内在联系。整体上，本文形成了“课件方法 - 代码实现 - 实验比较 - 结果分析”的完整实验流程。

7 结论

本文以课程课件中的典型算法为基础，完成了 K-means、SVM、BP 网络和 RBF 网络四类方法的统一仿真，并在主实验之外加入了 4 组附加对比实验。实验结果表明：

- K-means 在 Iris 数据集上能够反映样本的天然结构，但聚类评估需要同时关注内部指标与外部指标。
- RBF 核 SVM 是 Wine 数据上的强基线模型，准确率达到 97.78%。
- 基于 K-means 选中心的 RBF 网络在 Wine 数据集上表现极优，9 个中心时达到 100% 准确率。
- BP 网络在 Fashion-MNIST 子集上具备良好的图像分类能力，增加网络深度可以换取一定精度提升，但代价是更长训练时间。

后续工作可以从两个方向继续推进。第一，将课程中的 Fisher 判别、PCA、EM、SOM 等算法纳入同一实验框架，形成更完整的课程算法库。第二，在图像分类部分进一步引入卷积神经网络，对比 BP 网络与 CNN 在 Fashion-MNIST 或更复杂数据集上的差异。

A 复现实验所用文件说明

附录列出主要文件位置。

- 主脚本：`scripts/run_all.py`
- RBF 网络实现：`src/ml_course/rbf_network.py`
- 实验逻辑：`src/ml_course/experiments.py`
- 结果图表：`results/figures/` 与 `results/tables/`

参考文献

[1] J. MacQueen. Some Methods for Classification and Analysis of Multivariate Observations. In Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, Volume 1, pages 281–297, 1967.

[2] Corinna Cortes and Vladimir Vapnik. Support-Vector Networks. Machine Learning, 20(3):273–297, 1995.

[3] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning Representations by Back-Propagating Errors. Nature, 323:533–536, 1986.

[4] John Moody and Christian J. Darken. Fast Learning in Networks of Locally-Tuned Processing Units. Neural Computation, 1(2):281–294, 1989.

[5] R. A. Fisher. The Use of Multiple Measurements in Taxonomic Problems. Annals of Eugenics, 7(2):179–188, 1936.

[6] UCI Machine Learning Repository. Iris Dataset. DOI: https://doi.org/10.24432/C56C76.

[7] UCI Machine Learning Repository. Wine Dataset. DOI: https://doi.org/10.24432/C5PC7J.

[8] Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. arXiv preprint arXiv:1708.07747, 2017.